Reconocimiento de Actividades con Acelerómetro

Antonio Álvarez, Diego Besada, Natalia Corchón y Alfonso Jimena

16 de abril de 2026

Índice

1. Introducción **2**

2. Análisis exploratorio de datos **2**

3. Modelado **7**

3.1. Random Forest 7

3.2. CNN-1D 7

3.3. CNN-1D + LSTM 8

3.4. Transformer 8

3.5. Dual-Stream CNN 9

4. Resultados **13**

1. Introducción

Este trabajo aborda la clasificación automática de actividades físicas a partir de señales inerciales registradas en condiciones reales. La adquisición de datos se realizó con una Raspberry Pi conectada a un acelerómetro triaxial, registrando de forma continua las componentes X, Y y Z del movimiento.

Cada captura original corresponde a una secuencia de 40 segundos. A partir de esa señal larga se aplicó un proceso de recorte y segmentación para generar muestras más pequeñas, homogéneas y comparables entre sí. Estas ventanas recortadas son las unidades que finalmente se utilizan para entrenar y evaluar los modelos.

El objetivo del sistema es predecir, para cada muestra, una de las cuatro clases del challenge:

1. SKIP 2. TWIST 3. JUMP 4. STEP

Sobre este conjunto se estudian distintos enfoques de modelado, desde métodos clásicos hasta arquitecturas profundas, con el fin de comparar su capacidad de discriminación y su robustez para reconocer actividades en sujetos no vistos durante el entrenamiento.

2. Análisis exploratorio de datos

En esta fase realizamos un análisis exploratorio completo de las señales del acelerómetro en sus tres ejes (X, Y, Z) con dos objetivos: validar la calidad de los datos y entender qué rasgos pueden ayudar a separar actividades.

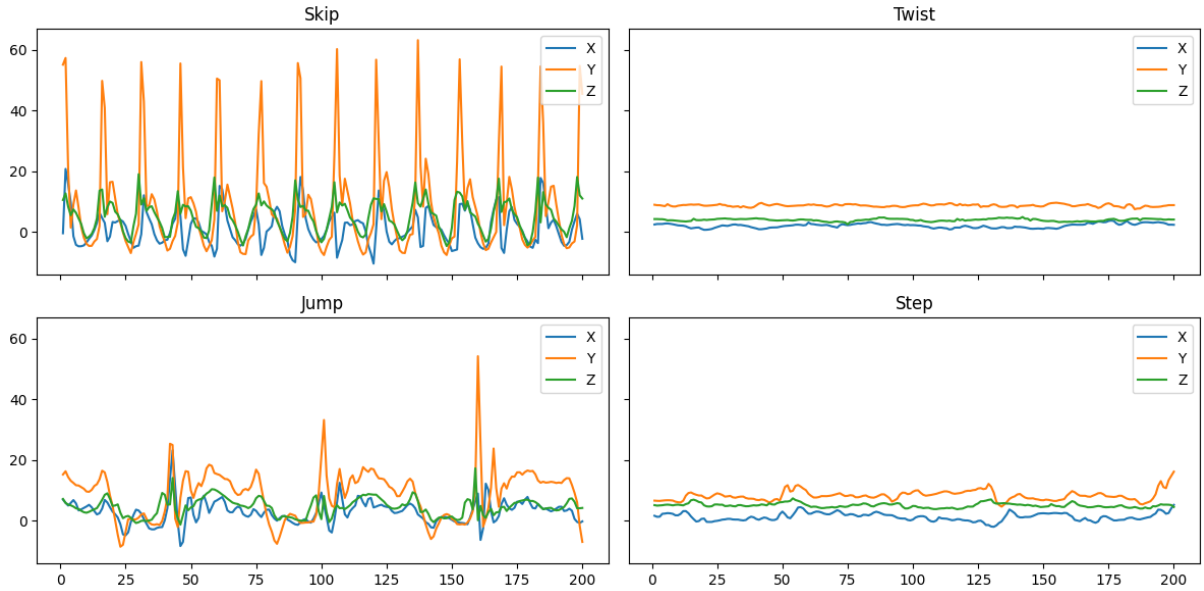

Figura 1: Visualización de muestras del acelerómetro en las distintas actividades.

La Figura 1 muestra ejemplos de muestras por clase. A simple vista hay diferencias de amplitud y ritmo. Esto no ocurre en todos los casos del dataset, a continuación, visualizaremos un ejemplo de la actividad que realizó uno de los usuarios:

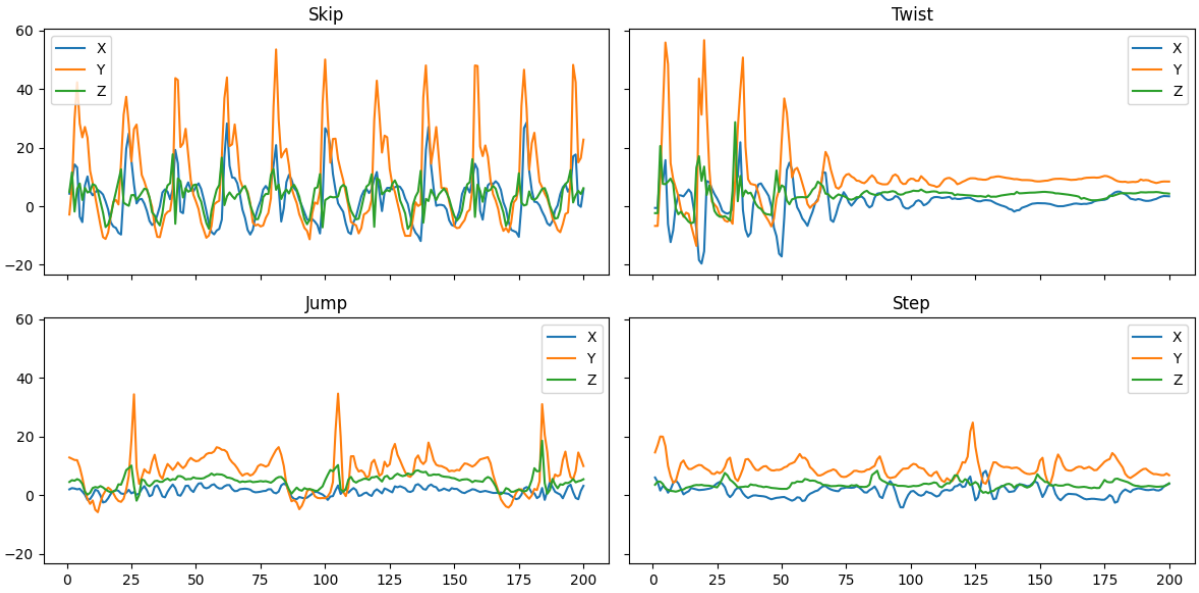

Figura 2: Visualización de muestras del acelerómetro en las distintas actividades.

Se puede observar una energía excesiva en twist que se asemeja más a un skip. Y pasa lo mismo entre las clases jump y step, no hay tanta diferencia como nos gustaría. Esto indudablemente representa un desafío para los modelos que podamos entrenar, ya que en muchas de las ocasiones, dados los datos, ni un humano podría distinguir entre las actividades.

Extracción y análisis de características

A partir de las señales del acelerómetro se calcularon distintas características temporales, dinámicas y espectrales con el objetivo de estudiar qué información separa mejor las actividades. El análisis conjunto de estas métricas muestra que existe cierta estructura discriminativa, aunque con solapamiento importante entre clases y una variabilidad notable entre sujetos. Esta observación anticipa la proyección t-SNE que se muestra más adelante, donde se verá visualmente que las clases forman grupos relativamente compactos, pero con zonas de mezcla coherentes con ese solapamiento.

Las características se organizaron en tres familias para facilitar su interpretación:

Intensidad del movimiento. Estas variables resumen cuánta energía contiene cada ventana y cómo se reparte la amplitud de la señal:

- `energia_total`: energía total de la señal.
- `rms`: raíz cuadrada media de la magnitud del acelerómetro.
- `sma`: suma de las magnitudes absolutas de las componentes.

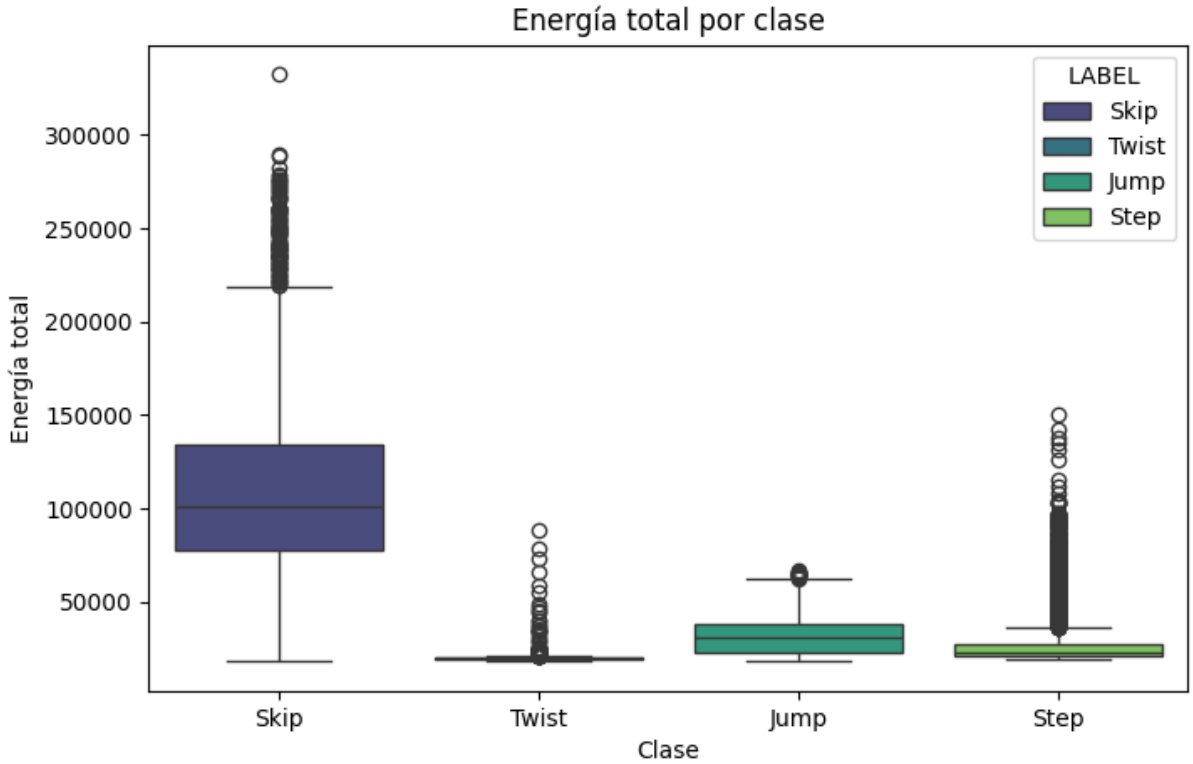

Figura 3: Distribución de energía total por clase en el conjunto de entrenamiento.

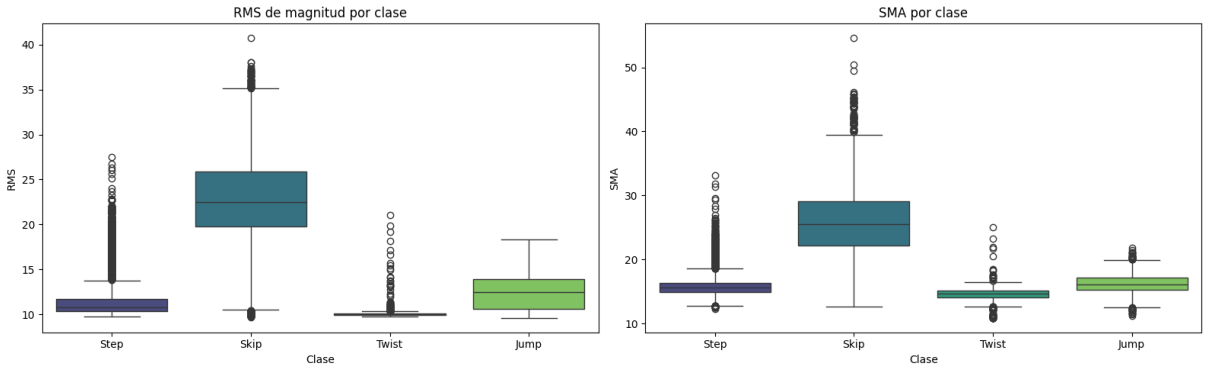

Figura 4: Comparación de métricas temporales de intensidad (RMS y SMA) por clase.

Periodicidad y brusquedad. Este segundo bloque captura el ritmo de la señal y la presencia de cambios rápidos de aceleración:

- `zcr_mean`: tasa media de cruces por cero, relacionada con la cadencia.
- `jerk_rms`: intensidad media de los cambios bruscos de aceleración.

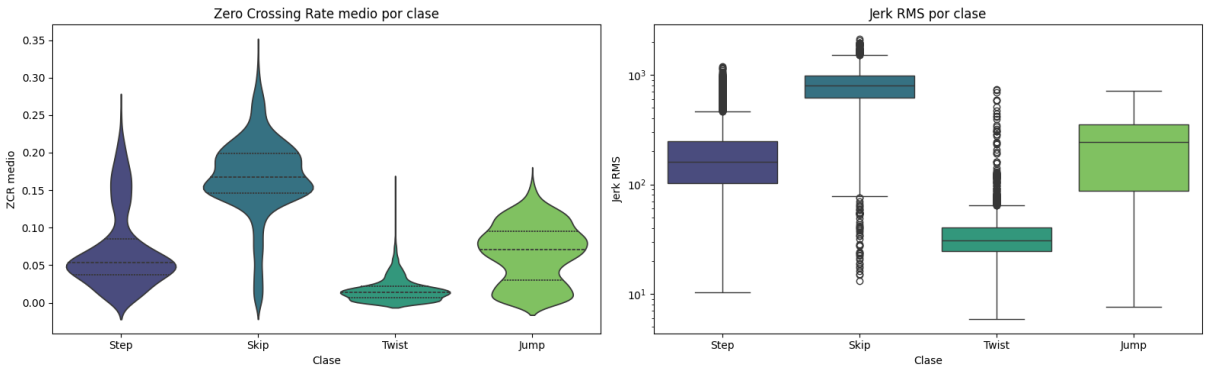

Figura 5: Métricas de periodicidad y dinámica (ZCR medio y Jerk RMS) por clase.

Estructura espectral. Estas métricas describen cómo se distribuye la energía en frecuencia y cuánta regularidad presenta la señal:

- `spectral_entropy`: medida de dispersión de la energía en frecuencia.
- `autocorr_lag1`: autocorrelación a un retardo, como indicador de regularidad temporal.
- PSD, frecuencia dominante, centroide espectral y potencia por bandas.

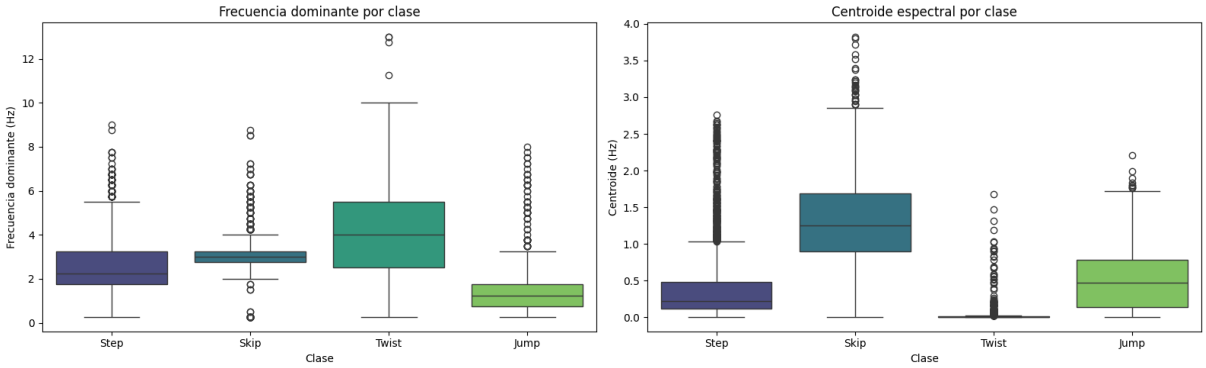

Figura 6: Frecuencia dominante y centroide espectral por clase.

t-SNE sobre las características extraídas

La proyección t-SNE sobre las características escaladas permite visualizar que, aunque existen agrupamientos aproximados por actividad, las fronteras entre clases no son nítidas y se observa un solapamiento considerable. Para cuantificar esta observación, se calcularon métricas de agrupamiento no supervisado sobre el espacio de características manuales: el índice ARI fue 0.31, el NMI 0.39 y el coeficiente Silhouette 0.37. Estos valores reflejan que, si bien las features extraídas contienen información útil, la separación entre actividades es limitada y existe bastante mezcla entre grupos.

En definitiva, apoyarse únicamente en este conjunto de características manuales impone una limitación clara: o bien sería necesario diseñar nuevas métricas más discriminativas, o bien recurrir a modelos capaces de aprender representaciones automáticamente a partir de la señal cruda, como ocurre en el aprendizaje profundo.

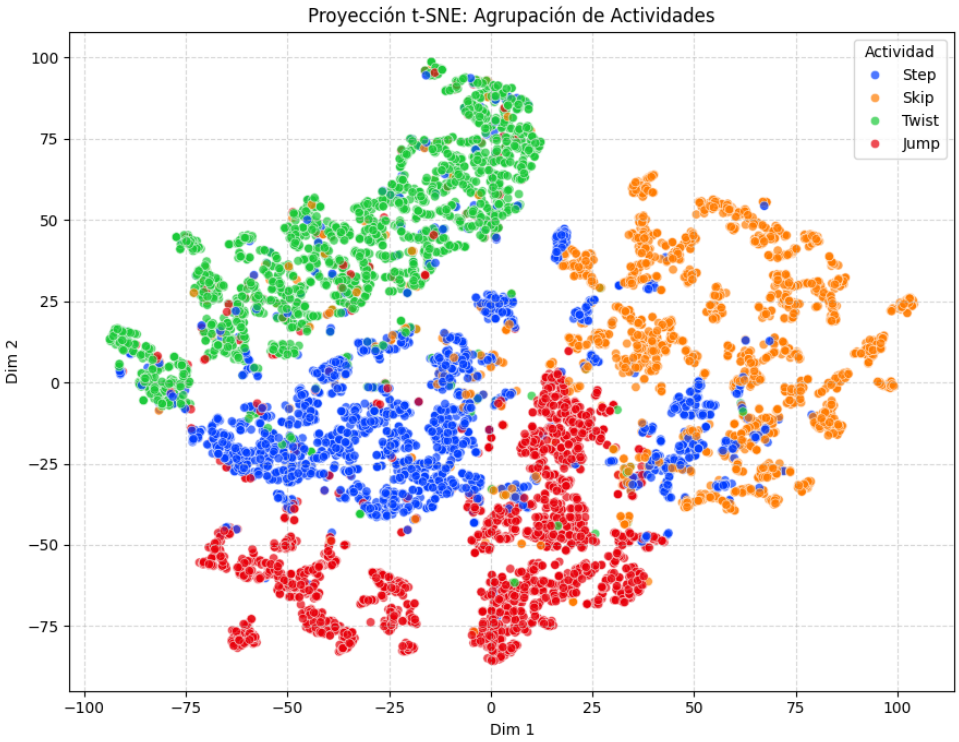

Figura 7: Proyección t-SNE de las *features* escaladas para visualizar agrupación por actividad.

3. Modelado

En esta sección se describen en detalle los distintos modelos evaluados: **Random Forest**, **CNN-1D**, **CNN-1D + LSTM**, **Transformer** y **Dual-Stream CNN**. Se explica el tipo de entrada utilizada, la arquitectura y las principales decisiones de diseño. Los resultados se dejan para una sección posterior, en la que se compararán estos modelos.

3.1. Random Forest

El modelo Random Forest utiliza exactamente las mismas características manuales extraídas en el análisis exploratorio (intensidad, periodicidad, brusquedad, frecuencia y complejidad). Como reflejan las métricas de agrupamiento (ARI, NMI, Silhouette), estas features permiten cierta discriminación pero presentan limitaciones claras, por lo que el rendimiento del modelo está condicionado por ellas.

Se realizó una búsqueda aleatoria de hiperparámetros con validación cruzada por usuario. La mejor configuración encontrada fue:

- `bootstrap=True`
- `max_depth=None`
- `max_features='log2'`
- `min_samples_leaf=5`
- `min_samples_split=5`
- `n_estimators=544`

A pesar de las limitaciones mencionadas, el modelo obtiene un resultado muy competitivo, mostrando que estas características manuales, aunque imperfectas, capturan información relevante para la tarea.

3.2. CNN-1D

En este modelo se emplea la señal cruda del acelerómetro como entrada, sin recurrir a extracción manual de características. La motivación principal es que una red convolucional 1D es capaz de aprender automáticamente, a partir de los datos, los patrones temporales relevantes para la clasificación de actividades. Así, el propio modelo puede identificar y explotar regularidades, picos, oscilaciones o secuencias características que podrían pasar desapercibidas en un enfoque basado en features manuales.

La normalización por canal se aplica para evitar sesgos de escala entre ejes. Gracias a este enfoque, el modelo es capaz de aprovechar toda la riqueza temporal de la señal y superar las limitaciones de la extracción manual de características. Como se verá en la sección de resultados, este salto hacia el aprendizaje automático de representaciones permite mejorar el rendimiento respecto a los métodos clásicos basados en features diseñadas a mano.

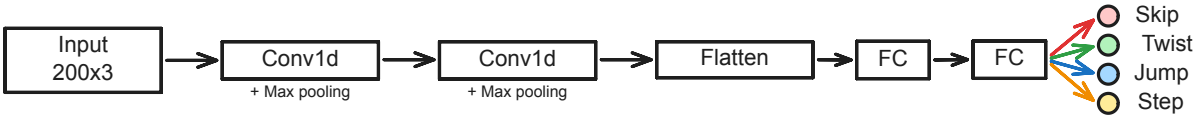

Figura 8: Esquema de la arquitectura CNN-1D utilizada.

Podemos ver que la estructura se limita a dos partes. Una primera sección convolucional que nos permite extraer patrones y una fully connected que se encarga de la clasificación final.

3.3. CNN-1D + LSTM

Este modelo es una evolución directa de la CNN-1D, añadiendo una LSTM tras la extracción convolucional para capturar dependencias temporales largas. La LSTM (Long Short-Term Memory) es un tipo de red recurrente diseñada para retener información relevante a lo largo de secuencias, lo que permite modelar la dinámica global de la actividad.

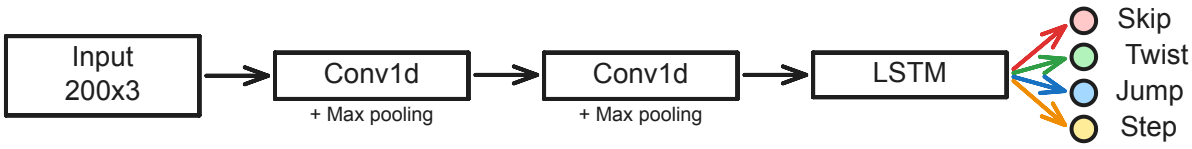

Figura 9: Esquema de la arquitectura CNN-1D+LSTM utilizada.

Añadido a la estructura anterior, se incorpora una capa LSTM que permite capturar patrones temporales más complejos. Se han eliminado capas fully connected intermedias porque la LSTM ya genera una representación compacta de la secuencia, a priori suficiente para la clasificación final mediante una única capa de salida.

3.4. Transformer

Este modelo es una evolución natural de los anteriores: en vez de usar convoluciones o LSTM, emplea un encoder Transformer para procesar la secuencia cruda del acelerómetro.

La arquitectura consiste en una proyección lineal de la entrada a 64 dimensiones, seguida de una codificación posicional sinusoidal que introduce información sobre el orden temporal de la señal. El núcleo del modelo es un encoder Transformer con 3 capas y 4 cabezas de atención, que permite relacionar distintos instantes de la secuencia, incluso si están separados en el tiempo. Tras el encoder se aplica un pooling global (media temporal) para obtener una representación única, que finalmente se clasifica mediante una única capa fully connected. Esto se puede ver en el siguiente esquema:

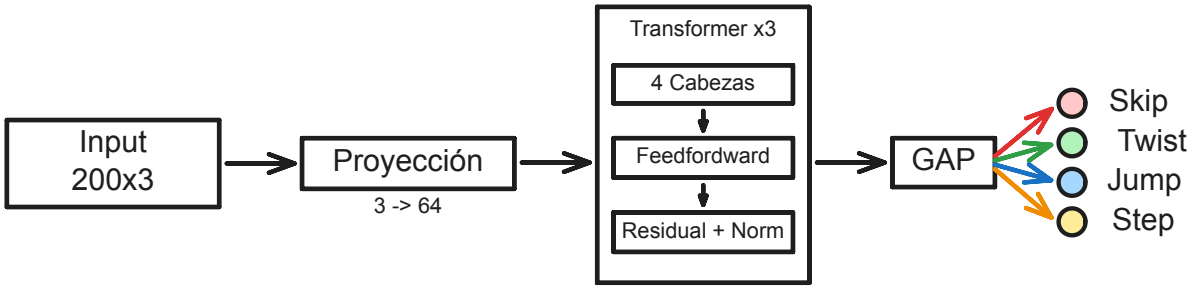

Figura 10: Esquema de la arquitectura Transformer utilizada.

3.5. Dual-Stream CNN

El Dual-Stream CNN es el modelo en el que más esfuerzo de diseño hemos invertido a lo largo del proyecto. Se trata de una arquitectura desarrollada para procesar las señales del acelerómetro en dos dominios complementarios. En vez de tratar la señal del acelerómetro como una simple serie temporal, cada ventana se transforma en bancos de espectrogramas multicanal. La entrada se divide en dos ramas: una temporal y otra espectral, cada una con 6 canales. Esta separación permite que la red especialice una rama en detectar eventos súbitos y patrones temporales, y la otra en capturar regularidades rítmicas y estructura frecuencial, combinando ambas para una visión global y robusta de la actividad.

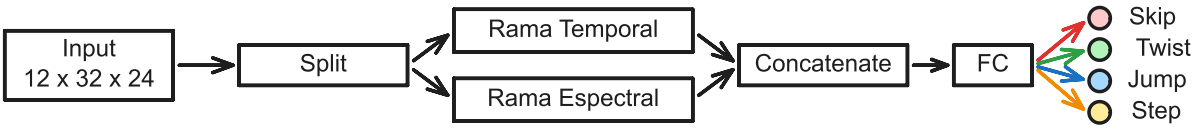

Figura 11: Arquitectura Dual-Stream CNN: entrada espectro-temporal, doble camino residual, fusión de características y clasificador final.

Los canales usados como entrada de la red se componen de:

- **Señales base:** las componentes originales del acelerómetro (X, Y, Z).
- **AlturaZ:** aproximación de la altura a partir de la componente Z.
- **AlturaXYZ:** como el sensor probablemente no está perfectamente alineado, se calcula la altura a partir de la magnitud total del vector de aceleración, asumiendo que todos los movimientos son verticales (aunque no es cierto, sirve como aproximación alternativa que puede usar la red).
- **Envolvente:** mide cómo varía la intensidad del movimiento a lo largo de la ventana.

A continuación, vemos como son estos canales en la práctica:

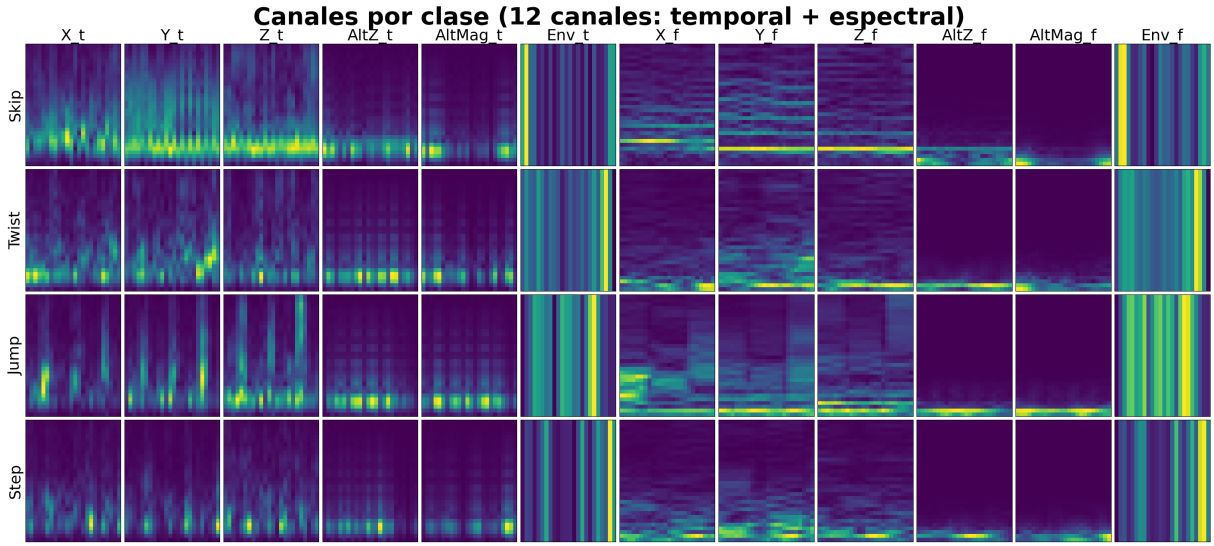

Figura 12: Ejemplo de espectrogramas usados como entrada del modelo.

Durante el proceso de diseño, se han tomado decisiones clave que afectan directamente al rendimiento y la capacidad de generalización del modelo. Estas son las decisiones más relevantes:

- La arquitectura 11 emplea bloques residuales tipo ResNet con activaciones SiLU (Sigmoid Linear Unit) y Batch Normalization en ambas ramas. Las conexiones de salto (skip connections) evitan el problema del gradiente desvaneciente y facilitan el aprendizaje profundo, mientras que la función SiLU, más suave que ReLU, favorece la convergencia en datos de sensores y mejora la estabilidad del entrenamiento.

- Para mejorar la capacidad de generalización y evitar el sobreajuste, durante el entrenamiento se aplica aumentación de datos. La forma en la que la hemos aplicado consiste en enmascarar aleatoriamente regiones del espectrograma en el dominio temporal y frecuencial. Esto simula la ausencia de información en ciertas bandas y obliga al modelo a aprender representaciones más robustas ante variaciones y ruido en los datos.

- En la etapa de clasificación, se utiliza label smoothing (suavizado de etiquetas) configurando la función de pérdida con `label_smoothing=0.1`. Esta técnica evita que el modelo se vuelva excesivamente seguro de sus predicciones, penalizando menos los errores pequeños y favoreciendo una mejor generalización ante sujetos no vistos.

Como este era el modelo que más confianza nos transmitía desde un inicio, fue el elegido para hacer el proceso completo, añadiendo validación LOSO:

El modelo se entrena y evalúa N veces, dejando siempre un sujeto completo fuera para test. Esto garantiza que la métrica de accuracy obtenida refleja la capacidad real del sistema para generalizar a personas nuevas, evitando el sesgo de memorizar estilos individuales. Dada esta estrategia, se ha logrado un resultado medio de 0.956 de accuracy, con un **intervalo de confiaza** del 95 % que va desde el 94.6162 % hasta el 96.5934 %.

Finalmente, se puede entrenar el modelo con el conjunto de datos completo. Esto debe hacerse con cuidado para evitar el sobreajuste. La estrategia seguida ha sido monitorizar la evolución de la accuracy en el conjunto de validación durante el entrenamiento para poder elegir el número de épocas óptimo. Lo vemos en la siguiente figura:

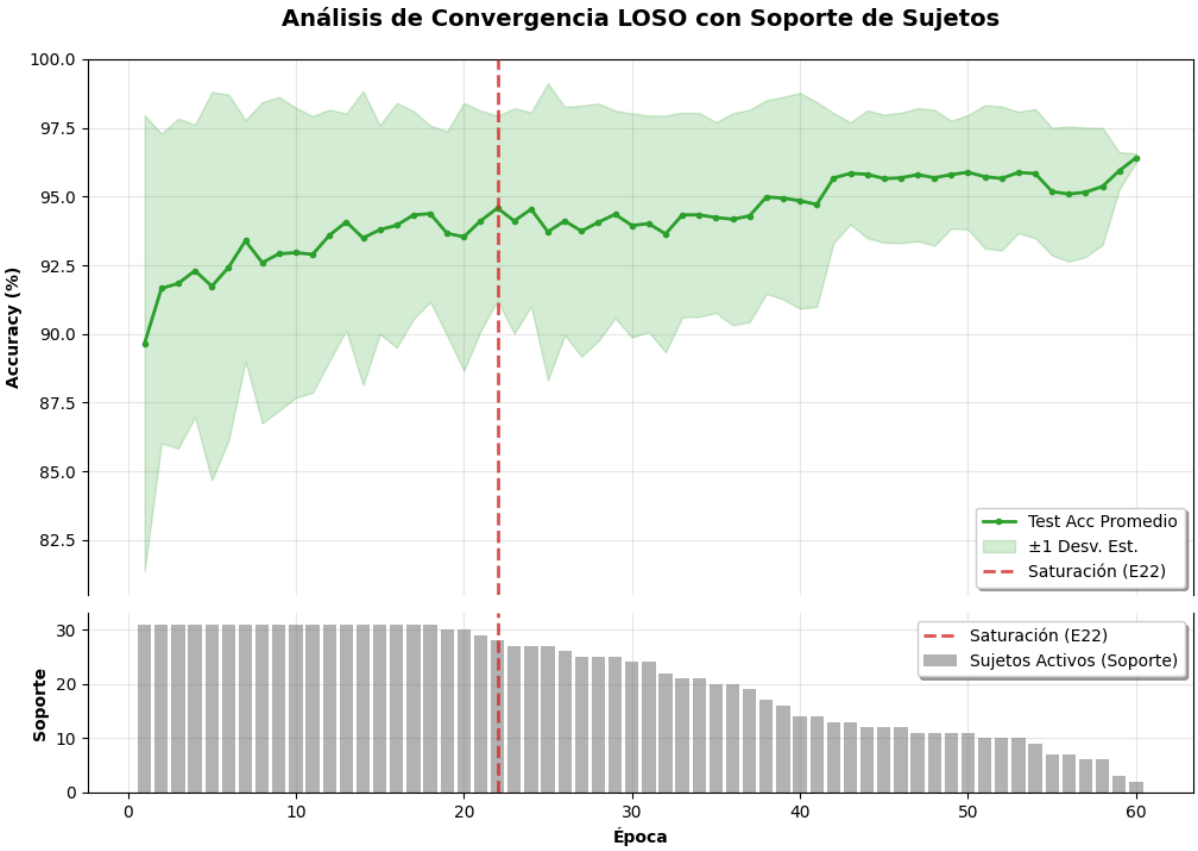

Figura 13: Evolución de la accuracy durante el entrenamiento con validación LOSO.

Para finalizar esta sección, se muestra la versión completa del flujo 14, incluyendo la separación explícita por ramas temporal y espectral, los bloques residuales y la etapa de fusión antes de la clasificación.

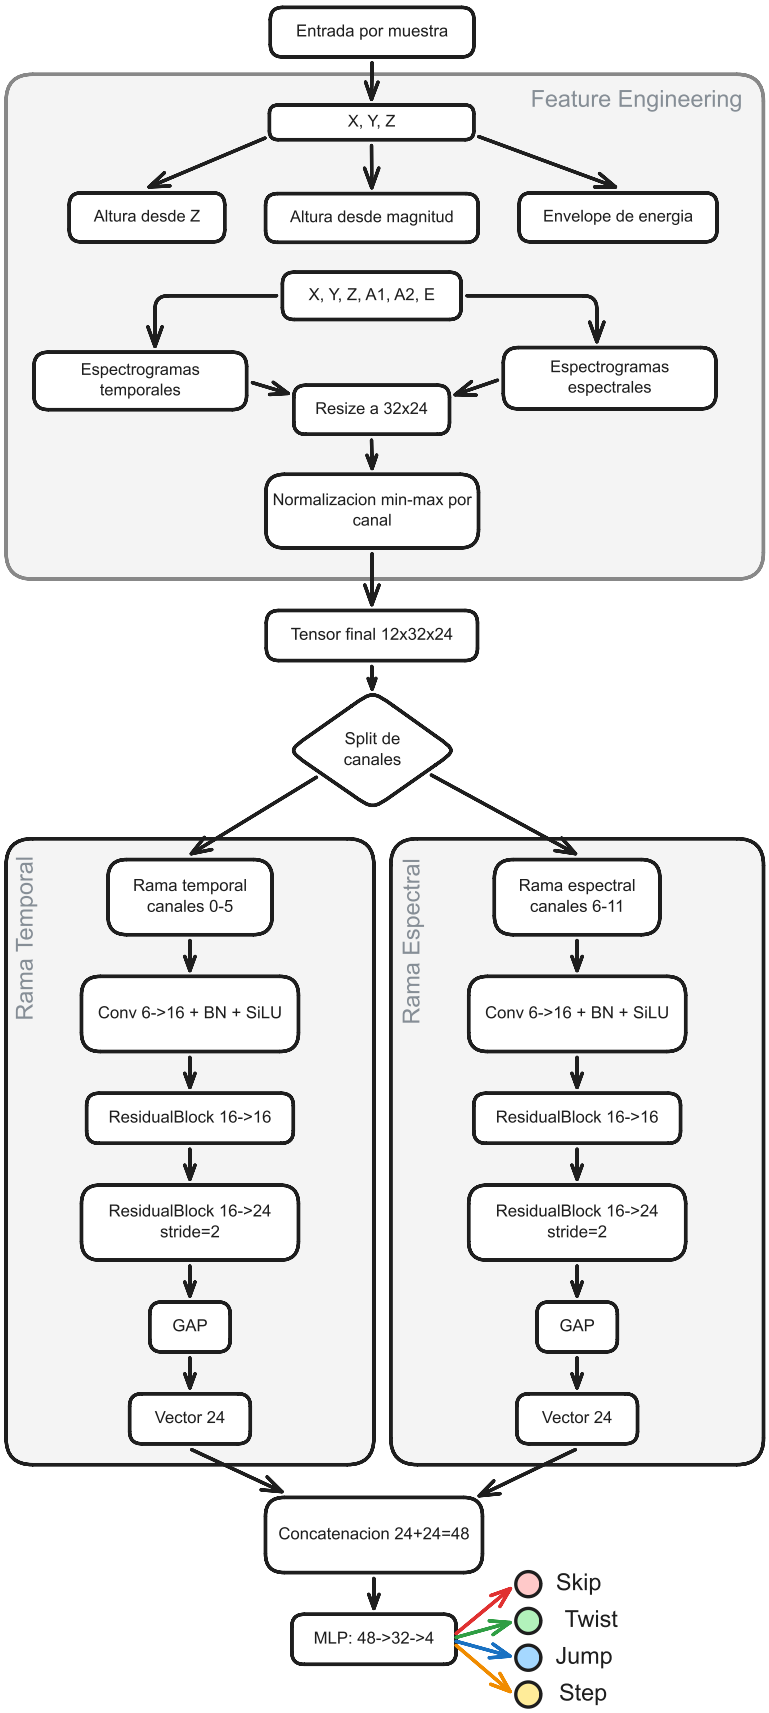

Figura 14: Arquitectura Dual-Stream CNN detallada: flujo completo por rama temporal y espectral, bloques residuales y cabeza de clasificación.

4. Resultados

Todos los modelos han sido entrenados y evaluados usando una partición 80/20 por grupos de sujeto: el 80 % de los sujetos se emplea para entrenamiento y el 20 % restante para validación, asegurando que no haya solapamiento de sujetos entre ambos conjuntos. Este enfoque permite evaluar la capacidad de generalización de los modelos a sujetos no vistos durante el entrenamiento.

Las matrices de confusión en validación muestran que los modelos basados en redes neuronales capturan mejor la estructura de las actividades que el enfoque clásico con Random Forest. En general, la clase **TWIST** es la más consistente, mientras que la confusión más repetida aparece entre **SKIP** y **STEP**, dos actividades con patrones temporales y energéticos relativamente próximos en ciertas ventanas.

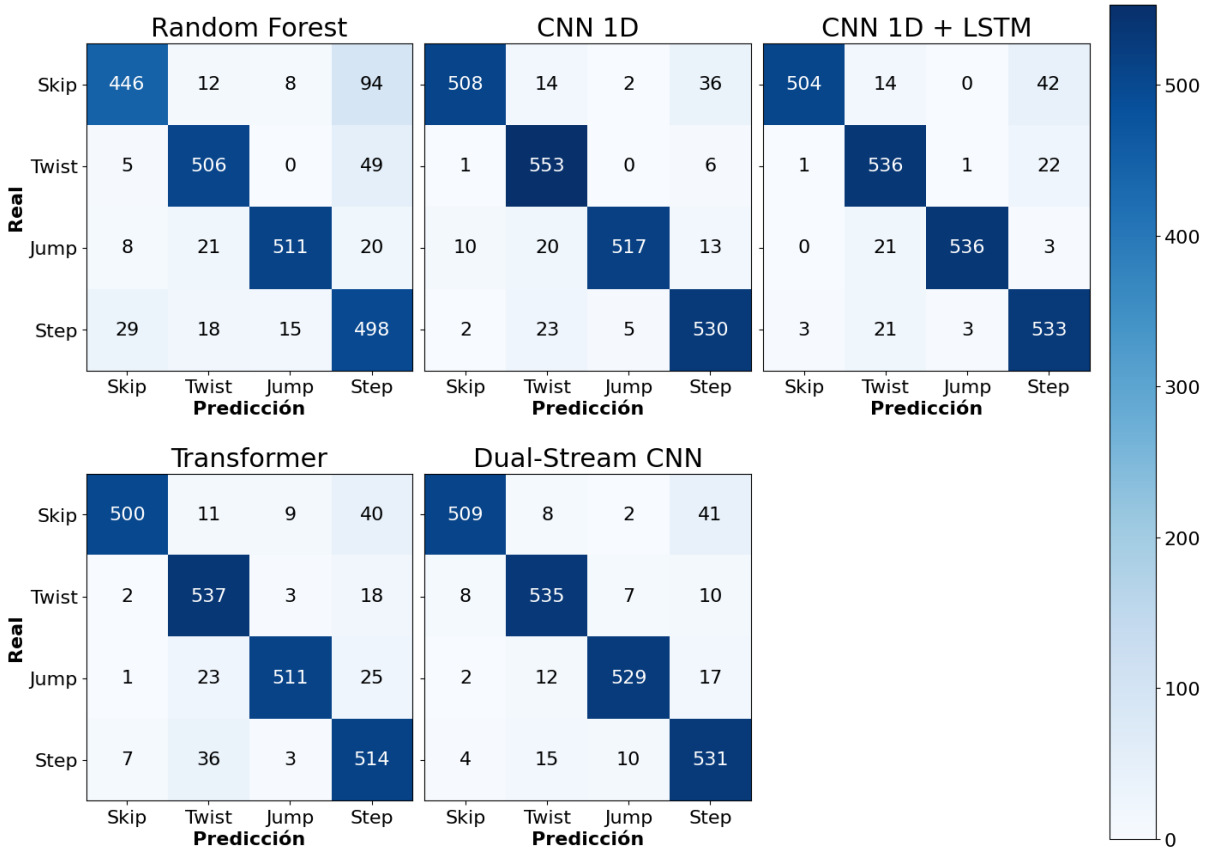

Figura 15: Comparativa de matrices de confusión en validación.

Visualización logarítmica: Para facilitar la identificación de los errores de clasificación menos frecuentes, se muestra también una versión logarítmica de las matrices de confusión ($\log_{10}(1 + x)$). Esta transformación resalta visualmente las confusiones entre clases que, en escala lineal, quedarían ocultas por la predominancia de los valores altos en la diagonal principal.

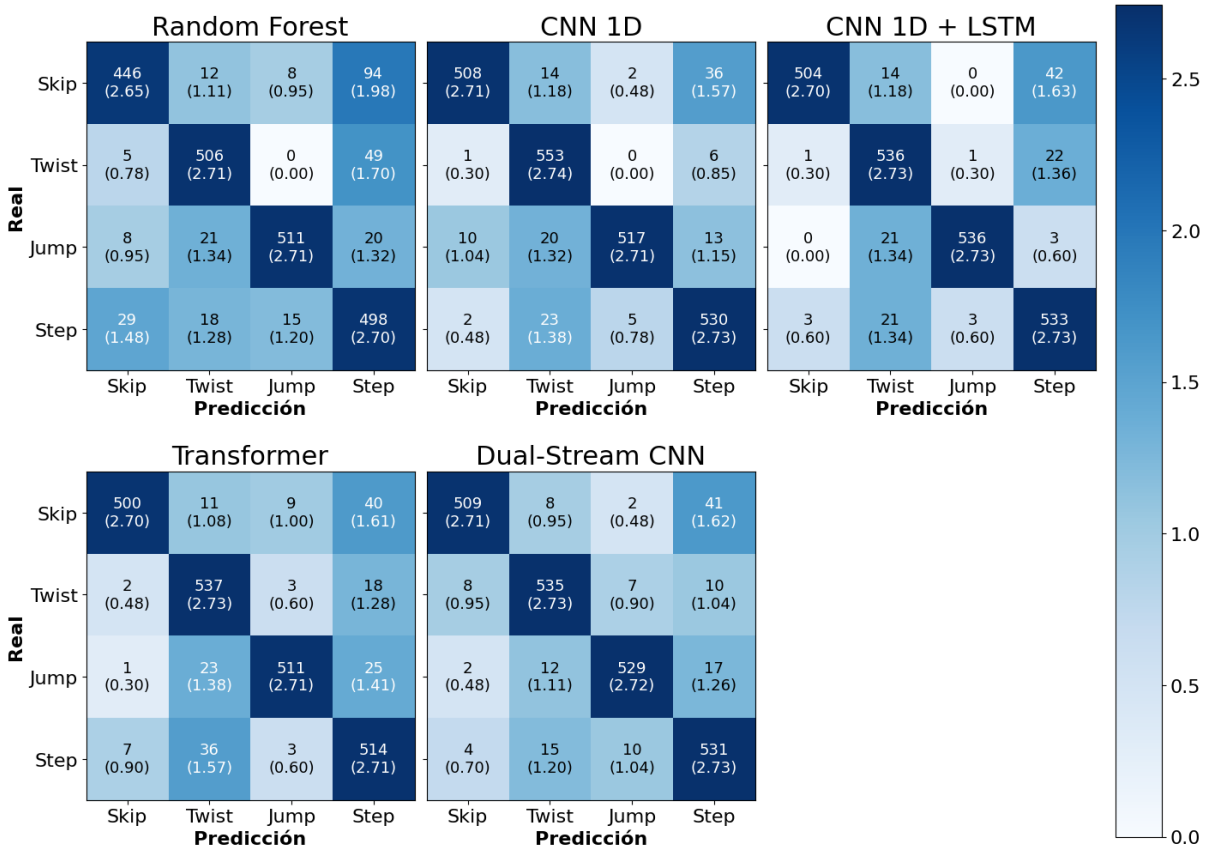

Figura 16: Comparativa de matrices de confusión en validación (escala logarítmica)

La siguiente figura resume las métricas clave empleadas para evaluar y comparar los modelos presentados:

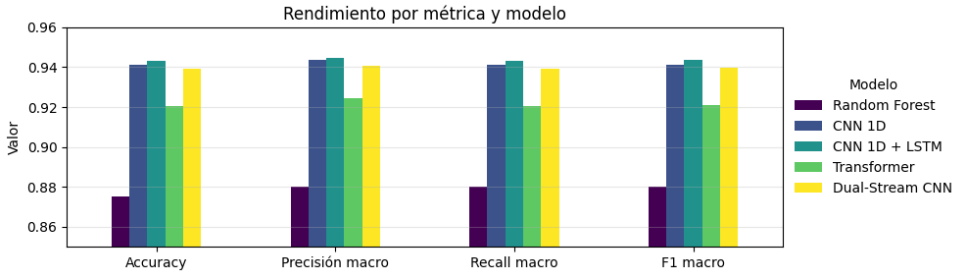

Figura 17: Evaluación del rendimiento de los modelos.

A pesar de que el modelo basado en la CNN-1D + LSTM parece obtener el mejor resultado según las métricas anteriores, es el modelo Dual-Stream CNN el que se ha seleccionado para realizar las predicciones finales en el test set. Esto se debe a la confianza que este modelo ha demostrado en la validación LOSO, prueba que no se ha realizado para el resto de modelos.